

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук

должность, уч. степень, звание

подпись, дата

Н. В. Богословская

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ № 3

ПОДГОТОВКА ПРИЗНАКОВ

по курсу:

БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № _____ 4326

подпись, дата

Г. С. Томчук

инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Цель работы: изучить методы подготовки признаков для анализа больших данных и освоить их реализацию в платформе Loginom с использованием визуальных компонентов и узла Python.

2 Задание

В ходе выполнения работы необходимо выполнить следующие задачи:

1. Удаление и заполнение пропущенных значений
2. Обнаружение и обработка выбросов
3. Масштабирование признаков (нормализация и стандартизация)
4. Отбор признаков на основе корреляционного анализа

Методы подготовки признаков реализовать с использованием Python и встроенных инструментов Loginom. Сравнить подходы обработки данных и сформулировать выводы о преимуществах различных методов.

3 Ход выполнения

Аналитический сценарий проекта представлен на рисунке 1




Рисунок 1 — Аналитический сценарий

На рисунках 2–11 представлены код, настройки узлов и результаты выполнения основных компонентов анализа.

```
1 import builtin_data
2 from builtin_data import InputTable, InputTables, InputVariables, OutputTable, OutputTables, DataType, DataKind, UsageType
3
4 import numpy as np, pandas as pd
5 from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
6
7 if InputTable:
8     # Создать pd.DataFrame по входному набору
9     data = to_data_frame(InputTable)
10
11 shutoff = 0.25
12 data = data[data.columns[data.isnull().mean() < shutoff]]
13 data = data.loc[data.isnull().mean(axis=1) < shutoff]
14
15 # Полученный выходной pd.DataFrame
16 output_frame = pd.DataFrame(data)
17
18 # Если включена опция "Разрешить формировать выходные столбцы из кода", структуру выходного набора можно подготовить по pd.DataFrame
19 if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
20     prepare_compatible_table(OutputTable, output_frame, with_index=False)
21 fill_table(OutputTable, output_frame, with_index=False)
22
```

Рисунок 2 — Аналитический сценарий

Исходные данные упорядочены ☐

Допустимый процент пропусков

Random seed

№	Входные поля	Вид данных		Метод обработки
	Фильтрация			
1	12 ID	Непрерывный	☐	Не выбран
2	12 male	Непрерывный	☒	Удалять записи
3	12 age	Непрерывный	☒	Заменять медианой
4	12 education	Непрерывный	☒	Заменять случайными значениями
5	12 currentSmoker	Непрерывный	☒	Заменять средним
6	12 cigsPerDay	Непрерывный	☒	Заменять на 0
7	12 BPMeds	Непрерывный	☒	Заменять наиболее вероятным
8	12 prevalentStroke	Непрерывный	☐	Не выбран
9	12 prevalentHyp	Непрерывный	☐	Не выбран
10	12 diabetes	Непрерывный	☐	Не выбран
11	12 totChol	Непрерывный	☐	Не выбран
12	9.0 sysBP	Непрерывный	☐	Не выбран
13	9.0 diaBP	Непрерывный	☐	Не выбран
14	9.0 BMI	Непрерывный	☐	Не выбран
15	12 heartRate	Непрерывный	☐	Не выбран
16	12 TenYearCHD	Непрерывный	☐	Не выбран
17	12 glucose	Непрерывный	☐	Не выбран

Рисунок 3 — Аналитический сценарий

```

1 import builtin_data
2 from builtin_data import InputTable, InputTables, InputVariables, OutputTable, OutputTables, DataType, DataKind, UsageType
3
4 import numpy as np, pandas as pd
5 from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
6
7 if InputTable:
8     # Создать pd.DataFrame по входному набору
9     data = to_data_frame(InputTable)
10
11 data["education"] = data["education"].fillna(data["education"].max()).astype(int)
12
13 data["BPMeds"] = data["BPMeds"].fillna(data["BPMeds"].min()).astype(int)
14 data["totChol"] = data["totChol"].fillna(data["totChol"].min()).astype(int)
15
16 data["BMI"] = data["BMI"].fillna(20).astype(int)
17
18 median_heart_rate = data["heartRate"].median()
19 median_glucose = data["glucose"].median()
20 data["heartRate"].fillna(median_heart_rate, inplace=True)
21 data["glucose"].fillna(median_glucose, inplace=True)
22
23 data.fillna(data.median(numeric_only=True), inplace=True)
24
25 # Полученный выходной pd.DataFrame
26 output_frame = pd.DataFrame(data)
27
28 # Если включена опция "Разрешить формировать выходные столбцы из кода", структуру выходного набора можно подготовить по pd.DataFrame
29 if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
30     prepare_compatible_table(OutputTable, output_frame, with_index=False)
31 fill_table(OutputTable, output_frame, with_index=False)
32

```

Рисунок 4 — Аналитический сценарий

```

1 import builtin_data
2 from builtin_data import InputTable, InputTables, InputVariables, OutputTable, OutputTables, DataType, DataKind, UsageType
3
4 import numpy as np, pandas as pd
5 from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
6
7 if InputTable:
8     # Создать pd.DataFrame по входному набору
9     data = to_data_frame(InputTable)
10
11 x = 3
12 upper_limit = data["cigsPerDay"].mean() + data["cigsPerDay"].std() * x
13 lower_limit = data["cigsPerDay"].mean() - data["cigsPerDay"].std() * x
14 data = data[(data["cigsPerDay"] < upper_limit) & (data["cigsPerDay"] > lower_limit)]
15
16 # Полученный выходной pd.DataFrame
17 output_frame = pd.DataFrame(data)
18
19 # Если включена опция "Разрешить формировать выходные столбцы из кода", структуру выходного набора можно подготовить по pd.DataFrame
20 if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
21     prepare_compatible_table(OutputTable, output_frame, with_index=False)
22 fill_table(OutputTable, output_frame, with_index=False)
23

```

Рисунок 5 — Аналитический сценарий

```

1 import builtin_data
2 from builtin_data import InputTable, InputTables, InputVariables, OutputTable, OutputTables, DataType, DataKind, UsageType
3
4 import numpy as np, pandas as pd
5 from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
6
7 if InputTable:
8     # Создать pd.DataFrame по входному набору
9     data = to_data_frame(InputTable)
10
11 upper_limit = data["cigsPerDay"].quantile(0.95)
12 lower_limit = data["cigsPerDay"].quantile(0.05)
13 data = data[(data["cigsPerDay"] < upper_limit) & (data["cigsPerDay"] > lower_limit)]
14
15 # Полученный выходной pd.DataFrame
16 output_frame = pd.DataFrame(data)
17
18 # Если включена опция "Разрешить формировать выходные столбцы из кода", структуру выходного набора можно подготовить по pd.DataFrame
19 if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
20     prepare_compatible_table(OutputTable, output_frame, with_index=False)
21 fill_table(OutputTable, output_frame, with_index=False)
22

```

Рисунок 6 — Аналитический сценарий

```

1 import builtin_data
2 from builtin_data import InputTable, InputTables, InputVariables, OutputTable, OutputTables, DataType, DataKind, UsageType
3
4 import numpy as np, pandas as pd
5 from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
6
7 if InputTable:
8     # Создать pd.DataFrame по входному набору
9     data = to_data_frame(InputTable)
10
11 upper_limit = data["cigsPerDay"].quantile(0.95)
12 lower_limit = data["cigsPerDay"].quantile(0.05)
13 data.loc[(data["cigsPerDay"] > upper_limit), "cigsPerDay"] = upper_limit
14 data.loc[(data["cigsPerDay"] < lower_limit), "cigsPerDay"] = lower_limit
15
16 # Полученный выходной pd.DataFrame
17 output_frame = pd.DataFrame(data)
18
19 # Если включена опция "Разрешить формировать выходные столбцы из кода", структуру выходного набора можно подготовить по pd.DataFrame
20 if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
21     prepare_compatible_table(OutputTable, output_frame, with_index=False)
22 fill_table(OutputTable, output_frame, with_index=False)
23

```

Рисунок 7 — Аналитический сценарий

Исходные данные упорядочены ☐

☐ Входные поля	Вид данных
Фильтрация	
☐ 12 ID	☐ Непрерывный
☐ 12 male	☐ Непрерывный
☐ 12 age	☐ Непрерывный
☐ 12 education	☐ Непрерывный
☐ 12 currentSmoker	☐ Непрерывный
☒ 90 cigsPerDay	☐ Непрерывный
☐ 12 BPMeds	☐ Непрерывный
☐ 12 prevalentStroke	☐ Непрерывный
☐ 12 prevalentHyp	☐ Непрерывный
☐ 12 diabetes	☐ Непрерывный
☐ 12 totChol	☐ Непрерывный
☐ 90 sysBP	☐ Непрерывный
☐ 90 diaBP	☐ Непрерывный
☐ 12 BMI	☐ Непрерывный
☐ 90 heartRate	☐ Непрерывный
☐ 12 TenYearCHD	☐ Непрерывный
☐ 90 glucose	☐ Непрерывный

Рисунок 8 — Аналитический сценарий

```

1 import builtin_data
2 from builtin_data import InputTable, InputTables, InputVariables, OutputTable, OutputTables, DataType, DataKind, UsageType
3
4 import numpy as np, pandas as pd
5 from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
6
7 import matplotlib.pyplot as plt
8
9 if InputTable:
10     # Создать pd.DataFrame по входному набору
11     data = to_data_frame(InputTable)
12
13     for column in data.columns:
14         data[column] = (data[column] - data[column].min()) / (data[column].max() - data[column].min())
15
16 #data.plot.bar()
17
18 # Полученный выходной pd.DataFrame
19 output_frame = pd.DataFrame(data)
20
21 # Если включена опция "Разрешить формировать выходные столбцы из кода", структуру выходного набора можно подготовить по pd.DataFrame
22 if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
23     prepare_compatible_table(OutputTable, output_frame, with_index=False)
24     fill_table(OutputTable, output_frame, with_index=False)
25

```

Рисунок 9 — Аналитический сценарий

☒ Коэффициент корреляции Пирсона
 ☐ Экстремум взаимнокорреляционной функции

☐ Коэффициент Тау-б Кендалла
 ☐ Коэффициент корреляции Спирмена

Входные колонки	☒ Набор 1	☒ Набор 2
12 ID	☒	☒
12 male	☒	☒
12 age	☒	☒
12 education	☒	☒
12 currentSmoker	☒	☒
90 cigsPerDay	☒	☒
12 BPMeds	☒	☒
12 prevalentStroke	☒	☒
12 prevalentHyp	☒	☒
12 diabetes	☒	☒
12 totChol	☒	☒
90 sysBP	☒	☒
90 diaBP	☒	☒
12 BMI	☒	☒
90 heartRate	☒	☒
12 TenYearCHD	☒	☒
90 glucose	☒	☒

Рисунок 10 — Аналитический сценарий

Корр. анализ • Быстрый просмотр					
Выходной набор данных					
#	ab Поле1.Имя	ab Поле1.Метка	ab Поле2.Имя	ab Поле2.Метка	98 Пирсона
1	ID	ID	ID	ID	1.00
2	male	male	ID	ID	0.02
3	age	age	ID	ID	0.01
4	education	education	ID	ID	0.00
5	currentSmoker	currentSmoker	ID	ID	0.01
6	cigsPerDay	cigsPerDay	ID	ID	0.01
7	BPMeds	BPMeds	ID	ID	0.02
8	prevalentStroke	prevalentStroke	ID	ID	0.02
9	prevalentHyp	prevalentHyp	ID	ID	0.02
10	diabetes	diabetes	ID	ID	0.03
11	totChol	totChol	ID	ID	-0.00
12	sysBP	sysBP	ID	ID	0.01
13	diaBP	diaBP	ID	ID	0.01
14	BMI	BMI	ID	ID	0.00
15	heartRate	heartRate	ID	ID	0.03
16	TenYearCHD	TenYearCHD	ID	ID	-0.01
17	glucose	glucose	ID	ID	0.02
18	ID	ID	male	male	0.02
19	male	male	male	male	1.00
20	age	age	male	male	-0.03
21	education	education	male	male	0.02
22	currentSmoker	currentSmoker	male	male	0.20
289	cigsPerDay	cigsPerDay	male	male	0.31

Рисунок 11 — Аналитический сценарий

4 Выводы

В ходе выполнения лабораторной работы были рассмотрены методы подготовки признаков, применяемые при анализе данных. Были выполнены операции обработки пропущенных значений, обнаружения и обработки выбросов, масштабирования числовых признаков, а также корреляционного анализа для оценки взаимосвязи переменных.

Практическая часть показала, что платформа Loginom предоставляет удобные визуальные инструменты для выполнения основных операций предобработки данных. Использование встроенных компонентов позволяет быстро реализовывать типовые этапы подготовки данных без необходимости написания кода, что упрощает разработку и ускоряет создание аналитических сценариев.

Одновременно применение узла Python расширяет возможности обработки данных. Программный подход позволяет более гибко управлять логикой преобразования данных, реализовывать нестандартные методы

обработки и комбинировать различные алгоритмы анализа.

Таким образом, использование визуальных инструментов платформы для базовых операций и программирования на Python для более сложных задач позволяет эффективно выполнять подготовку признаков и повышает гибкость процесса анализа данных.