

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук
должность, уч. степень, звание

подпись, дата

Н. В. Богословская
инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ № 4

КЛАСТЕРИЗАЦИЯ

по курсу:

БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № _____ 4326

подпись, дата

Г. С. Томчук
инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Цель работы: освоение методов кластерного анализа данных в аналитической платформе Loginom. В рамках работы необходимо изучить и практически применить алгоритмы кластеризации (ЕМ, k-means, g-means, CLOPE), провести оценку качества полученных моделей, а также выполнить содержательную интерпретацию сформированных кластеров.

2 Задание

В ходе выполнения работы необходимо выполнить следующие задачи:

1. Для двух наборов данных «Высшее образование.xlsx» и «Здравоохранение.xlsx» — реализовать кластеризацию алгоритмами ЕМ, k-means и g-means.
2. Для набора «transactions_diy.lgd» реализовать кластеризацию транзакций с помощью алгоритма CLOPE.
3. Выполнить оценку качества всех полученных моделей с использованием компонента «Кластерные силуэты» («meta-silhouettes») из библиотеки loginom_sklearn_meta.
4. Предложить интерпретацию полученных кластеров.
5. Разработать визуальные отчёты для изучения полученных кластеров.

3 Ход выполнения

3.1 Подготовка данных

На начальном этапе лабораторной работы были загружены три набора исходных данных: «Высшее образование.xlsx», «Здравоохранение.xlsx» и «transactions_diy.lgd». Общая структура разработанного сценария представлена на рисунке 1.

Перед выполнением кластерного анализа данные из файлов формата XLSX были предварительно обработаны. Из таблиц были исключены записи, содержащие нечисловые значения в полях, используемых при кластеризации. Такая подготовка необходима, поскольку рассматриваемые алгоритмы работают с числовыми признаками и используют расстояние между объектами для определения степени их сходства.

После очистки данные передавались в узел Python, в котором выполнялась нормализация числовых признаков методом Min-Max. Нормализация позволяет привести значения различных характеристик к единому масштабу и тем самым исключить чрезмерное влияние признаков с большими абсолютными значениями на результат кластеризации.

В Python-узле автоматически определялись числовые поля набора данных. Служебные столбцы, используемые в качестве идентификаторов или счетчиков, например «#», «id», «ID» и «№», исключались из обработки. При необходимости значения преобразовывались в числовой формат, после чего для каждого признака выполнялось масштабирование. Для контроля корректности обработки в консоль выводились минимальные и максимальные значения соответствующих столбцов до выполнения нормализации.




Рисунок 1 — Аналитический сценарий

3.2 Определение оптимального числа кластеров методом «локтя»

Для выбора подходящего количества кластеров был применен метод

«локтя» (Elbow Method). Он основан на последовательном выполнении кластеризации при различных значениях количества кластеров k и последующем анализе внутрикластерной суммы квадратов отклонений WCSS.

При увеличении количества кластеров значение WCSS постепенно уменьшается, поскольку объекты внутри каждого кластера располагаются ближе к его центру. Однако после определенного значения k дальнейшее увеличение числа кластеров приводит лишь к незначительному улучшению результата. На графике зависимости WCSS от k эта область проявляется в виде характерного перегиба, называемого «локтем».

Для автоматизации данного процесса в LogiNot была создана отдельная подмодель, содержащая кластеризацию с изменяемым количеством кластеров. В ней были определены переменные, необходимые для выполнения итераций. Далее с помощью узла «Цикл» было выполнено 20 последовательных итераций. На каждой итерации количество кластеров увеличивалось, после чего сохранялось соответствующее значение WCSS. Полученные результаты представлены на рисунке 2.

По построенной зависимости WCSS от количества кластеров был выполнен анализ положения наиболее выраженного перегиба кривой. В результате оптимальным было принято значение $k = 7$. Начиная с данного значения дальнейшее увеличение числа кластеров уже не обеспечивает существенного уменьшения внутрикластерного разброса. График, использованный для выбора значения k , представлен на рисунке 3.

Таблица 1				
#	12 StartK	12 Iter	98 Кв Расст	Сумма
1	2	20		275.05
2	3	19		226.85
3	4	18		165.43
4	5	17		139.81
5	6	16		114.36
6	7	15		98.37
7	8	14		81.20
8	9	13		76.00
9	10	12		65.89
10	11	11		60.94
11	12	10		55.17
12	13	9		51.92
13	14	8		47.86
14	15	7		44.31
15	16	6		41.86
16	17	5		40.54
17	18	4		39.24
18	19	3		35.42
19	20	2		32.99
20	21	1		32.06

Рисунок 2 — Таблица итераций




Рисунок 3 — Диаграмма для определения оптимального числа кластеров

3.3 Кластеризация алгоритмом k-means

Одним из используемых в работе методов являлся алгоритм k-means. Его задача заключается в разделении исходного множества объектов на

заранее заданное количество кластеров таким образом, чтобы объекты внутри одного кластера были максимально похожи друг на друга, а расстояние от объектов до соответствующих центроидов было минимальным.

После выполнения предобработки и нормализации наборы данных «Высшее образование» и «Здравоохранение» были переданы на вход компонента «Кластеризация k-means». Количество кластеров было установлено равным 7 в соответствии с результатами, полученными методом «локтя».

В результате работы алгоритма каждой записи исходного набора данных был присвоен номер соответствующего кластера. Кроме того, Logiplot сформировал характеристики полученных групп, позволяющие сравнивать их между собой и анализировать особенности объектов, вошедших в каждый кластер.

Результат разбиения данных алгоритмом k-means представлен на рисунке 4.




Рисунок 4 — Профили кластеров k-means

3.4 Кластеризация алгоритмом g-means

Вторым рассмотренным алгоритмом являлся g-means. В отличие от

классического k-means, данный метод способен автоматически определять необходимое количество кластеров в процессе обработки данных.

Работа алгоритма начинается с относительно небольшого количества групп. Далее для каждого полученного кластера анализируется распределение содержащихся в нем объектов. Если оно не соответствует заданным статистическим критериям, кластер разделяется на несколько новых групп. Процесс продолжается до тех пор, пока дальнейшее разделение не перестает быть обоснованным.

Для выполнения кластеризации нормализованные данные из наборов «Высшее образование» и «Здравоохранение» были переданы в компонент «Кластеризация g-means». В отличие от k-means, вручную задавать итоговое количество кластеров для этого алгоритма не требовалось.

Структура части сценария, содержащей компоненты g-means и k-means, представлена на рисунке 5. Полученные результаты кластеризации методом g-means приведены на рисунке 6.




Рисунок 5 — Фрагмент сценария для g-means и k-means




Рисунок 6 — Профили кластеров g-means для таблицы «Высшее образование»

По результатам кластеризации методом g-means было сформировано три кластера регионов. Наиболее многочисленным является кластер 2, включающий 49% объектов. Для него характерны значения показателей высшего образования несколько выше среднего уровня, поэтому данный кластер можно охарактеризовать как регионы с развитой системой высшего образования. Кластер 1 включает 48% регионов и характеризуется пониженными значениями числа образовательных организаций, численности студентов, приема и выпуска, что позволяет отнести его к регионам с относительно низким уровнем развития высшего образования. Кластер 0 является наиболее малочисленным и включает 3,7% регионов. Для него характерны существенно более высокие значения практически всех рассматриваемых показателей, особенно численности студентов, приема, выпуска и обеспеченности преподавательским персоналом. Данный кластер соответствует крупнейшим образовательным центрам с высокой концентрацией организаций и студентов.

3.5 Кластеризация алгоритмом ЕМ

В рамках работы также рассматривался алгоритм ЕМ (Expectation-

Maximization). В отличие от k-means, который выполняет жесткое разбиение объектов на кластеры, ЕМ использует вероятностный подход. Для каждого объекта может быть определена вероятность его принадлежности к той или иной группе.

Алгоритм выполняется итерационно и состоит из двух основных этапов. На первом этапе производится оценка вероятности принадлежности объектов к имеющимся кластерам. На втором этапе на основании полученных вероятностей уточняются параметры распределений кластеров. Итерации продолжаются до стабилизации полученной модели.

Результат ЕМ-кластеризации представлен на рисунке 7.




Рисунок 7 — Профили ЕМ-кластеров

Таким образом, ЕМ позволяет учитывать случаи, когда границы между группами выражены недостаточно четко, а объекты могут иметь признаки сразу нескольких кластеров.

3.6 Кластеризация алгоритмом CLOPE

Помимо числовых наборов данных, в работе использовался транзакционный набор «transactions_diy.lgd». Для него применялся алгоритм CLOPE, предназначенный специально для кластеризации

транзакционных и категориальных данных.

Файл «transactions_diy.lgd» был подключен непосредственно к компоненту CLOPE. При настройке полей столбцу «Чек» было назначено назначение «Транзакция», а столбцу «Товарная группа» — назначение «Элемент», как показано на рисунке 8.

Такое представление позволяет алгоритму рассматривать каждый чек как отдельную транзакцию, состоящую из набора товарных групп. На основании повторяющихся сочетаний товаров CLOPE объединяет похожие транзакции в кластеры и позволяет выявлять характерные модели покупательского поведения.

Настройка входных данных представлена на рисунке 8, а результаты работы алгоритма CLOPE — на рисунке 9.

Фильтрация			
Метка	Имя	Вид данных	Назначение
ab Чек	BCode	Дискретный	Транзакция
ab Товарная группа	ItemGroup	Дискретный	Элемент
31 Дата продажи	TrDte	Непрерывный	Не задано
ab Клиент	ClientID	Дискретный	Не задано
ab Товар	Item	Дискретный	Не задано
90 Кол-во	Quantity	Непрерывный	Не задано
90 Сумма	Amount	Непрерывный	Не задано

Рисунок 8 — Настройка столбцов CLOPE

CLOPE: Чек, Товарная группа • Быстрый просмотр			
Разбиение на кластеры		Параметры кластеров	
#	ab Чек	12 Номер кластера	
1	code000000001	13	
2	code000000002	15	
3	code000000003	0	
4	code000000004	1	
5	code000000005	2	
6	code000000006	2	
7	code000000007	9	
8	code000000008	2	
9	code000000009	12	
10	code000000010	12	
11	code000000011	0	

#	12 Номер кластера	12 N	12 W	12 S
1	0	59,903	2	112,681
2	1	12,041	1	17,773
3	2	38,701	3	158,568
4	3	34,982	4	99,261
5	4	7,520	4	16,584
6	5	6,429	3	15,904
7	6	3,632	7	15,249
8	7	3,422	1	4,165
9	8	11,284	8	77,079
10	9	29,241	3	70,568
11	10	3,130	6	12,294
12	11	1,625	1	2,080
13	12	39,067	8	157,171
14	13	24,324	12	143,759
15	14	4,240	9	26,023
16	15	10,688	17	79,529

Рисунок 9 — Результат кластеризации CLOPE

3.7 Оценка качества кластеризации

После получения результатов кластеризации была выполнена оценка качества сформированных групп. Для этого использовался компонент

meta-silhouettes из библиотеки loginom_sklearn_meta.

Основным показателем являлся коэффициент силуэта. Он характеризует одновременно компактность объектов внутри собственного кластера и степень их отделенности от объектов соседних кластеров.

Значение коэффициента силуэта изменяется в диапазоне от -1 до 1. Значения, близкие к 1, означают, что объект хорошо соответствует своему кластеру и значительно удален от соседних кластеров. Значение около 0 указывает на нахождение объекта вблизи границы между двумя группами. Отрицательное значение может свидетельствовать о том, что объект потенциально был отнесен не к наиболее подходящему кластеру.

Для использования компонента meta-silhouettes в сценарий предварительно была подключена библиотека loginom_sklearn_meta. Затем с помощью узла «Параметры полей» из результатов кластеризации выделялось поле «Номер кластера». Для обеспечения совместимости с компонентом оно преобразовывалось в текстовый тип и передавалось на соответствующий вход meta-silhouettes.

Одинаковая процедура оценки применялась к результатам обработки наборов «Высшее образование» и «Здравоохранение». Для каждого набора анализировались результаты, полученные алгоритмами EM, k-means и g-means.

Графическое представление кластерных силуэтов для алгоритмов и наборов данных приведено на рисунках 10–15. По ним можно визуально оценить, насколько хорошо сформированы отдельные кластеры и присутствуют ли объекты, расположенные в пограничных областях.




Рисунок 10 — Проверка EM кластеризации для таблицы «Высшее образование»




Рисунок 11 — Проверка кластеризации k_means для таблицы «Высшее образование»




Рисунок 12 — Проверка кластеризации g-means для таблицы «Высшее образование»




Рисунок 13 — Проверка EM кластеризации для таблицы «Здравоохранение»




Рисунок 14 — Проверка кластеризации k_means для таблицы «Здравоохранение»




Рисунок 15 — Проверка кластеризации g_means для таблицы «Здравоохранение»

4 Выводы

В ходе выполнения лабораторной работы были изучены основные методы кластерного анализа и способы оценки полученных результатов в среде Loginom.

На этапе подготовки данных были обработаны наборы «Высшее

образование» и «Здравоохранение». Из исходных таблиц были исключены некорректные для дальнейшего анализа значения, после чего числовые признаки были нормализованы методом Min-Max. Это позволило привести характеристики объектов к сопоставимому масштабу и уменьшить влияние различий в диапазонах значений признаков.

Для определения количества кластеров был использован метод «локтя». В ходе нескольких итераций вычислялось значение внутрикластерной суммы квадратов WCSS при различном числе кластеров. На основании полученной зависимости было выбрано значение $k = 7$.

Далее данные были обработаны с применением алгоритмов k-means, g-means и EM. Алгоритм k-means выполнял разделение объектов на заранее заданное число кластеров. G-means позволил автоматически уточнять количество групп в зависимости от распределения объектов. EM использовал вероятностный подход, благодаря чему принадлежность объекта к кластеру могла рассматриваться не только как однозначная, но и с учетом соответствующих вероятностей.

Для набора «transactions_diy.lgd», содержащего транзакционные данные, был применен алгоритм CLOPE. С его помощью транзакции были объединены в группы на основании сходства содержащихся в них товарных категорий.

Качество кластеризации было дополнительно проанализировано с использованием коэффициента силуэта и компонента meta-silhouettes. Полученные диаграммы позволили оценить компактность сформированных кластеров и степень их отделенности друг от друга.

Таким образом, в процессе лабораторной работы были практически освоены процедуры подготовки данных, выбора количества кластеров, применения различных алгоритмов кластеризации и оценки качества полученного разбиения. Полученные результаты также позволяют выполнить дальнейшую содержательную интерпретацию сформированных групп и выявить характерные особенности объектов каждого кластера.