

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук

должность, уч. степень, звание

подпись, дата

Н. В. Богословская

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ № 6

РЕГРЕССИЯ

по курсу:

БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № 4326

подпись, дата

Г. С. Томчук

инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Цель работы: освоение методов регрессионного анализа данных с использованием аналитической платформы Loginom, а также сравнительная оценка эффективности различных алгоритмов линейной регрессии при решении прикладных задач.

2 Задание

В ходе выполнения работы необходимо выполнить следующие задачи:

1. Проведение анализа набора данных по недвижимости Российской Федерации за период 2018–2021 годов с применением методов предобработки данных и создания новых признаков для повышения качества моделирования;
2. Выполнение сравнительного анализа качества моделирования с использованием встроенного компонента Линейная регрессия платформы Loginom и моделей линейной регрессии из библиотеки sklearn, реализованных через компонент model.fitter из пакета loginom_sklearn_kit;
3. Осуществление регрессионного анализа временных рядов на примере данных о численности амбулаторно-поликлинических организаций в Российской Федерации за девятнадцатилетний период с учётом динамики изменения показателей;
4. Разработка прогностической модели для оценки склонности клиентов торговой сети к приобретению продуктов новой линии на основе социально-демографических характеристик и истории покупательского поведения с использованием случайной выборки в размере семидесяти процентов от общего объёма данных.

3 Ход выполнения

3.1 Подготовка данных и создание новых признаков

На первом этапе лабораторной работы был загружен набор данных о недвижимости России за период 2018–2021 годов, после чего в среде Loginom был открыт шаблон LinearReg_template.lgp. Основной задачей

данного этапа являлась подготовка исходных данных к дальнейшему построению регрессионных моделей.

В процессе работы со сценарием были сформированы дополнительные производные признаки на основе исходных характеристик объектов недвижимости. Создание новых признаков позволяет расширить исходное признаковое пространство и учитывать зависимости, которые не представлены непосредственно в исходном наборе данных. Общий вид загруженного сценария представлен на рисунке 1.

Перед построением моделей была выполнена предварительная проверка качества данных. Анализировалось наличие пропущенных значений, распределение отдельных показателей и возможное присутствие аномальных наблюдений. Для формирования новых характеристик использовались узлы «Калькулятор» и «Группировка».

С их помощью были получены дополнительные показатели, отражающие взаимосвязь отдельных параметров недвижимости, а также временные и агрегированные характеристики. Категориальные признаки дополнительно подготавливались к преобразованию в числовое представление, необходимое для использования большинства алгоритмов машинного обучения.

После завершения предобработки исходный набор данных был разделен для последующего обучения и проверки моделей. Результат данного этапа представлен на рисунке 2.




Рисунок 1 — Импорт данных




Рисунок 2 — Разбиение датасета

3.2 Построение моделей линейной регрессии

После подготовки исходных данных был реализован сценарий построения модели линейной регрессии. Для этого использовалась библиотека машинного обучения `sklearn`, подключенная к `Loginom` через компонент `model.fitter` из пакета `loginom_sklearn_kit`.

Одним из основных этапов подготовки данных являлось преобразование категориальных переменных в числовой формат. Для этого использовался узел `Binary Encoder`, выполняющий кодирование категорий с помощью битового представления. Такое преобразование позволяет передавать категориальные характеристики модели регрессии в виде числовых признаков.

Общая структура участка сценария, отвечающего за подготовку данных и построение линейной регрессионной модели, представлена на рисунке 4.

В качестве алгоритма была выбрана модель `Ridge` из модуля `sklearn.linear_model`. `Ridge` представляет собой вариант линейной регрессии с L2-регуляризацией. Использование регуляризации позволяет уменьшить влияние сильно коррелирующих между собой признаков и повысить устойчивость полученной модели.

Основные параметры алгоритма были оставлены без изменений. Для обеспечения воспроизводимости результатов параметру `random_state` было присвоено значение 42.




Рисунок 3 — Линейная регрессия с помощью узла Loginom




Рисунок 4 — Линейная регрессия с помощью Ridge

При настройке компонента model.fitter для переменной output_names было установлено значение predicted. В результате прогнозируемое моделью значение сохранялось в соответствующем поле выходного набора данных, что позволило в дальнейшем сравнивать его с фактическим значением целевой переменной.


После обучения была проведена оценка качества модели отдельно на обучающей и тестовой выборках. Такое разделение позволяет определить не только точность модели на уже известных данных, но и ее способность сохранять качество прогнозирования на ранее не использовавшихся наблюдениях.

Для обучающей выборки коэффициент детерминации R^2 составил 0,70. Следовательно, модель объясняет около 70% изменчивости целевой

переменной. Средняя ошибка прогнозирования составила 0,22.

На тестовой выборке значение R^2 снизилось до 0,62, а средняя ошибка составила 0,21. Небольшое снижение коэффициента детерминации относительно обучающей выборки ожидаемо при проверке модели на новых данных и не свидетельствует о критическом переобучении.

Полученные показатели качества линейной модели представлены на рисунке 5.



#	Метрика	Значение
1	r2	0.62
2	explained_variance	0.66
3	max_error	36,506,467.26
4	mean_absolute_error	2,106,543.47
5	mean_squared_log_error	
6	mean_squared_error	11,893,575,646,457.63
7	median_absolute_error	1,293,228.14
8	mean_absolute_percentage_error	0.21
9	d2_absolute_error_score	0.41

Рисунок 5 — Метрика линейной регрессии Ridge на тестовой выборке

3.3 Построение модели XGBRegressor и анализ значимости признаков

Для сравнения результатов линейной регрессии с более сложным методом машинного обучения была дополнительно построена модель XGBRegressor из библиотеки xgboost.

Алгоритм XGBRegressor относится к методам градиентного бустинга и использует ансамбль последовательно строящихся решающих деревьев. Каждое новое дерево корректирует ошибки, допущенные предыдущими моделями, что позволяет описывать сложные нелинейные зависимости между признаками и целевой переменной.

Общий вид части сценария, предназначенной для построения альтернативной модели, представлен на рисунке 6.

Перед передачей данных в XGBRegressor категориальные признаки также были преобразованы в числовой формат. В данном случае

использовался метод Ordinal Encoder, который заменяет каждую категорию соответствующим числовым кодом.

В отличие от линейных моделей, древовидные алгоритмы не используют числовое расстояние между закодированными категориями напрямую, поэтому подобный способ представления категориальных переменных может эффективно применяться при построении модели градиентного бустинга. Применение Ordinal Encoder показано на рисунке 7.




Рисунок 6 — Сценарий линейной регрессии с XGBRegressor




Рисунок 7 — Применение метода Ordinal Encoder

Модель XGBRegressor была обучена с основными параметрами по умолчанию. В ходе построения ансамбля последовательно создаются решающие деревья, совместная работа которых формирует итоговый прогноз.

Результаты показали заметное повышение качества на обучающей выборке по сравнению с моделью Ridge. Коэффициент детерминации R^2 достиг значения 0,94, а средняя ошибка прогнозирования составила около


0,1. Это означает, что модель очень хорошо описывает данные, использованные при обучении.

Результат прогнозирования для обучающей выборки представлен на рисунке 8.

На тестовой выборке значение коэффициента детерминации составило 0,68, а средняя ошибка — 0,24. Таким образом, качество на новых данных оказалось ниже, чем на обучающей выборке. Значительная разница между значениями R^2 указывает на наличие некоторого переобучения модели.

Несмотря на это, значение R^2 на тестовых данных у XGBRegressor оказалось выше, чем у модели Ridge, для которой оно составляло 0,62. Следовательно, в рамках данной задачи градиентный бустинг обеспечил более высокую точность прогнозирования.

Результаты проверки XGBRegressor на тестовой выборке представлены на рисунке 9.



The image shows a screenshot of a software interface displaying regression metrics. The title bar reads "regression metrics (выполнение) • Быстрый просмотр". Below the title, there is a section labeled "Выходной набор данных". The main content is a table with the following structure:

#	ab Метрика	9.0 Значение
1	r2	0.94
2	explained_variance	0.94
3	max_error	39,694,811.00
4	mean_absolute_error	658,311.30
5	mean_squared_log_error	0.02
6	mean_squared_error	1,344,719,744,681.94
7	median_absolute_error	376,648.50
8	mean_absolute_percentage_error	0.10
9	d2_absolute_error_score	0.77

Рисунок 8 — Прогнозирование обучающей выборки XGBRegressor

regression metrics (выполнение) • Быстрый просмотр		
Выходной набор данных		
#	ab Метрика	Значение
1	r2	0.68
2	explained_variance	0.81
3	max_error	28,799,381.00
4	mean_absolute_error	2,266,288.18
5	mean_squared_log_error	
6	mean_squared_error	10,008,661,962,377.21
7	median_absolute_error	1,690,472.50
8	mean_absolute_percentage_error	0.24
9	d2_absolute_error_score	0.36

Рисунок 9 — Прогнозирование тестовой выборки XGBRegressor

3.4 Регрессионный анализ временного ряда

Во второй части лабораторной работы был рассмотрен регрессионный анализ временного ряда. Для выполнения задания использовался файл «Число амбулаторно-поликлинических организаций.xlsx», содержащий значения показателя по Российской Федерации за 19 лет наблюдений.

После загрузки данных была проанализирована динамика изменения числа амбулаторно-поликлинических организаций во времени. Построение графического представления позволило оценить общий характер зависимости между годом наблюдения и исследуемым показателем.

Временной ряд демонстрировал выраженное изменение тренда, которое не полностью соответствовало простой линейной зависимости. В связи с этим для описания данных было целесообразно использовать нелинейную форму регрессии.

В рамках задания была построена гиперболическая регрессионная модель. Такая модель позволяет описывать зависимости, скорость изменения которых постепенно уменьшается или увеличивается при изменении независимой переменной.

Дополнительно оценивались основные характеристики динамики временного ряда и соответствие построенной кривой фактическим

значениям.

Результат построения гиперболической регрессионной модели представлен на рисунке 10.




Рисунок 10 — Гиперболическая регрессия

3.5 Моделирование склонности клиентов к покупке новых продуктов

В третьей части лабораторной работы исследовалось покупательское поведение клиентов торговой сети. Исходные данные были загружены из файла «Клиенты торговой сети.xlsx».

Набор данных содержал социально-демографические и поведенческие характеристики покупателей. Среди рассматриваемых признаков присутствовали пол клиента, возрастная группа, тип скидочной карты, продолжительность участия в программе лояльности, общая сумма совершенных покупок и категория совокупного семейного дохода.

В качестве целевой переменной использовалось количество приобретенных товаров, относящихся к группе новых продуктов. Таким образом, задача состояла в построении регрессионной зависимости,

позволяющей оценить склонность клиента к покупке новой продукции на основании имеющихся характеристик.

Перед построением модели была выполнена проверка структуры данных и типов признаков. Категориальные поля преобразовывались в числовую форму, после чего анализировалась их связь с целевой переменной.

Для описания зависимости была использована логарифмическая регрессия. Такая форма модели применяется в случаях, когда изменение результативного признака происходит нелинейно: увеличение значения фактора сначала оказывает заметное влияние на результат, но по мере его дальнейшего роста величина дополнительного эффекта постепенно снижается.

Полученная модель позволила описать зависимость количества покупок новых товаров от характеристик клиентов и их предыдущего покупательского поведения.

Результаты построения логарифмической регрессии представлены на рисунке 11.




Рисунок 11 — Логистическая регрессия

4 Выводы

В ходе лабораторной работы были изучены основные этапы построения регрессионных моделей в среде Loginom: подготовка исходных данных, создание дополнительных признаков, преобразование категориальных переменных, разделение выборки, обучение моделей и оценка качества прогнозирования.

Для решения задачи прогнозирования на данных о недвижимости были построены две модели: Ridge и XGBRegressor. Линейная модель Ridge показала коэффициент детерминации R^2 , равный 0,70 на обучающей и 0,62 на тестовой выборке. Полученные результаты свидетельствуют о достаточно устойчивом качестве модели и отсутствии выраженного переобучения.

Модель градиентного бустинга XGBRegressor продемонстрировала более высокую точность. На обучающей выборке значение R^2 составило 0,94, а на тестовой — 0,70. При этом существенная разница между результатами обучающей и тестовой выборок указывает на наличие переобучения. Несмотря на это, по качеству прогнозирования на тестовых данных XGBRegressor превзошел линейную модель.

Также в рамках работы был выполнен регрессионный анализ временного ряда на примере числа амбулаторно-поликлинических организаций. Для описания наблюдаемой нелинейной динамики использовалась гиперболическая регрессия.

В заключительной части была построена модель, описывающая склонность клиентов торговой сети к приобретению новых товаров. Для анализа использовалась логарифмическая зависимость, учитывающая нелинейный характер влияния социально-демографических и покупательских характеристик.

Таким образом, в ходе лабораторной работы были практически рассмотрены как линейные, так и нелинейные методы регрессионного анализа, а также ансамблевые методы машинного обучения. Сравнение результатов показало, что выбор алгоритма зависит от характера исходных данных и сложности существующих между признаками зависимостей.